

Universidad Austral

Maestría en Ciencia de Datos

Asignatura: Introducción a Data Mining

Trabajo Práctico

**Clasificación: árboles de decisión, clasificadores basados en reglas
y sobreajuste**

Modalidad: trabajo individual o en grupos

Partes A a E: resolución manuscrita. Parte F: resolución empleando software

1. Presentación y encuadre

El presente Trabajo Práctico integra los contenidos de la asignatura, dedicados a la clasificación. Su propósito es que el estudiante consolide, mediante la resolución de problemas, los fundamentos de la inducción de árboles de decisión, la evaluación de clasificadores, el diagnóstico y el control del sobreajuste, y la construcción de clasificadores basados en reglas. El trabajo combina ejercicios de cálculo manual, preguntas teóricas de desarrollo y un componente práctico de implementación en R o en el lenguaje o herramienta de su preferencia.

1.1. Objetivos de aprendizaje

Al finalizar el Trabajo Práctico, el estudiante será capaz de:

- Calcular medidas de impureza de nodos (índice de Gini y entropía) y la ganancia de información, y emplearlas como criterio de selección de atributos de partición.
- Inducir árboles de decisión manualmente a partir de conjuntos de datos de tamaño reducido.
- Determinar los puntos de corte óptimos para atributos continuos.
- Construir e interpretar la matriz de confusión y las métricas de desempeño derivadas de ella.
- Diagnosticar el sobreajuste y aplicar estrategias de poda y de control de la complejidad del modelo.
- Derivar, evaluar y aplicar clasificadores basados en reglas, tanto a partir de árboles como mediante métodos directos.
- Implementar, evaluar y comparar árboles de decisión y clasificadores de reglas en R.

1.2. Modalidad de trabajo y entrega

El Trabajo Práctico puede resolverse de forma individual o en grupos. Las Partes A a E deben resolverse “a mano”, exhibiendo la totalidad de los cálculos y las justificaciones; no se admiten respuestas sin desarrollo. La Parte F debe resolverse en R o con el software de su preferencia, y entregarse como un script reproducible (archivo .R) o como un documento R Markdown (.Rmd), acompañado de un informe en formato PDF que incluya el código, las salidas relevantes y la discusión de los resultados. El plazo de entrega será definido por la cátedra.

1.3. Criterios de evaluación

La calificación se compondrá de los siguientes criterios: corrección de los cálculos y procedimientos (40 %); justificación e interpretación de los resultados (30 %); calidad del código y reproducibilidad de la Parte F (20 %); y claridad en la presentación y la redacción (10 %).

1.4. Herramientas y conjuntos de datos

Para la Parte F se utilizará R (versión 4.3 o superior) con los paquetes `rpart`, `rpart.plot`, `caret`, `C50` y `mlbench`, en línea con el R Companion de la asignatura (Hahsler, 2025). Todos los conjuntos de datos necesarios para las Partes A a E se incluyen en el presente enunciado.

Parte A. Árboles de decisión: impureza e inducción

El Conjunto de Datos 1 (Tabla 1) registra 14 solicitudes de crédito. Cada solicitud se describe mediante tres atributos predictores (Ingreso, Historial crediticio y Deuda) y el atributo de clase Otorga, que indica si se otorgó el crédito.

Tabla 1. Conjunto de Datos 1 — Solicitudes de crédito.

N.º	Ingreso	Historial	Deuda	Otorga
1	Alto	Bueno	Baja	Sí
2	Alto	Bueno	Alta	Sí
3	Medio	Bueno	Baja	Sí
4	Bajo	Bueno	Baja	Sí
5	Bajo	Malo	Baja	No
6	Bajo	Malo	Alta	No
7	Medio	Malo	Alta	No
8	Alto	Malo	Baja	Sí
9	Medio	Bueno	Alta	Sí
10	Bajo	Bueno	Alta	No
11	Alto	Malo	Alta	Sí
12	Medio	Malo	Baja	No
13	Medio	Bueno	Baja	Sí
14	Bajo	Malo	Baja	No

Ejercicio 1. Medidas de impureza y selección del atributo raíz

Con base en el Conjunto de Datos 1:

- Calcule la entropía y el índice de Gini del nodo raíz, es decir, antes de realizar cualquier partición.
- Para cada uno de los tres atributos candidatos (Ingreso, Historial y Deuda), calcule la entropía ponderada de los nodos hijos y la ganancia de información correspondiente.
- Calcule asimismo el índice de Gini ponderado de cada atributo candidato y la reducción de la impureza de Gini que este produce.
- Indique qué atributo seleccionaría como raíz del árbol según la ganancia de información. ¿Coincide la elección con la que indicaría el índice de Gini? Justifique su respuesta.

Ejercicio 2. Inducción del árbol de decisión completo

A partir del atributo raíz seleccionado en el Ejercicio 1, continúe la inducción del árbol de decisión de manera recursiva, empleando la ganancia de información como criterio de partición, hasta que todos los nodos hoja sean puros o no queden atributos disponibles.

- Dibuje el árbol de decisión resultante. En cada nodo interno indique el atributo de partición y, en cada hoja, la clase predicha junto con la cantidad de instancias que contiene.
- Expresé el árbol en forma de pseudocódigo, mediante una estructura de reglas anidadas “**si... entonces...**”.
- ¿Cuántos nodos hoja tiene el árbol? ¿Cuál es su error de resustitución, es decir, su error sobre el propio conjunto de entrenamiento?

Ejercicio 3. Partición de un atributo continuo

El Conjunto de Datos 2 (Tabla 2) contiene 10 registros caracterizados por un atributo continuo, el Ingreso imponible (expresado en miles de pesos), y por el atributo de clase Evade, que indica si el contribuyente evade impuestos.

Tabla 2. Conjunto de Datos 2 — Ingreso imponible y evasión (registros ordenados por ingreso).

Registro	1	2	3	4	5	6	7	8	9	10
Ingreso imponible	60	70	80	95	100	110	115	120	130	140
Evade	No	No	No	Sí	No	Sí	Sí	Sí	Sí	No

- Enumere los puntos de corte candidatos, definidos como los puntos medios de los valores consecutivos del atributo ordenados.
- Para cada punto de corte candidato, calcule el índice de Gini ponderado de la partición binaria resultante.
- Indique el punto de corte óptimo y exprese la condición de prueba asociada al nodo.
- Explique por qué los árboles de decisión solo generan fronteras de decisión paralelas a los ejes de coordenadas.

Parte B. Evaluación de clasificadores

Ejercicio 4. Matriz de confusión y métricas de desempeño

Un clasificador binario fue evaluado en un conjunto de prueba de 100 pacientes para detectar una enfermedad. Se define como clase positiva “Enfermo” y como clase negativa “Sano”. El modelo produjo 35 verdaderos positivos, 15 falsos negativos, 10 falsos positivos y 40 verdaderos negativos.

- a) Construya la matriz de confusión correspondiente, identificando claramente la clase real y la predicha.
- b) Calcule la exactitud, la tasa de error, la precisión, la sensibilidad (recall), la especificidad y la medida F1.
- c) Calcule el estadístico kappa de Cohen e interprete su valor.
- d) Suponga que un falso negativo (no detectar a un paciente efectivamente enfermo) acarrea un costo mucho mayor que un falso positivo. ¿Qué métrica priorizaría para seleccionar el modelo? Justifique.

Parte C. Sobreajuste

Ejercicio 5. Diagnóstico del sobreajuste

La Tabla 3 presenta el error de un árbol de decisión sobre el conjunto de entrenamiento y sobre un conjunto de validación independiente, en función de la complejidad del modelo, medida como el número de nodos hoja.

Tabla 3. Error de entrenamiento y de validación según la complejidad del modelo.

Nodos hoja	Error de entrenamiento	Error de validación
1	0,42	0,45
3	0,30	0,33
5	0,22	0,26
7	0,16	0,21
9	0,12	0,19
15	0,06	0,20
25	0,02	0,27
40	0,00	0,34

- Represente gráficamente ambas curvas de error en función de la complejidad del modelo, en un mismo sistema de ejes.
- Identifique las regiones de subajuste y de sobreajuste, y señale la complejidad óptima.
- Explique por qué el error de entrenamiento decrece de forma monótona, mientras que el error de validación describe una curva en U.
- ¿Qué complejidad de modelo seleccionaría? Justifique su elección en términos del error de generalización.

Ejercicio 6. Poda mediante el error pesimista

Considere el subárbol descrito a continuación: un nodo interno contiene 40 instancias del conjunto de entrenamiento, de las cuales 28 pertenecen a la clase “+” y 12 a la clase “-”. Dicho nodo se divide en cuatro nodos hoja, cuyas distribuciones de clase se detallan en la Tabla 4.

Tabla 4. Distribución de clases en los nodos hoja del subárbol del Ejercicio 6.

Nodo hoja	Instancias “+”	Instancias “-”
L1	8	2
L2	8	2
L3	7	2
L4	5	6

- Calcule el error de entrenamiento del nodo antes de la división (tratándolo como hoja) y después de la división.

- b) Calcule el error de generalización pesimista antes y después de la división, penalizando cada nodo hoja con un factor de 0,5. Recuerde que el error pesimista se define como $(\text{errores} + k \cdot 0,5) / N$, donde k es el número de hojas y N el número de instancias.
- c) A partir de la comparación de los errores pesimistas, ¿debería podarse el subárbol? Justifique su respuesta.
- d) ¿Qué relación tiene este procedimiento con el principio de parsimonia, conocido como la navaja de Occam?

Ejercicio 7. Estrategias de control del sobreajuste

Responda de forma fundamentada a las siguientes consignas:

- a) Distinga la pre-poda (detención temprana) de la post-poda. Indique una ventaja y una desventaja de cada estrategia.
- b) Mencione tres criterios de pre-poda que se utilicen habitualmente en la inducción de árboles de decisión.
- c) Un colega afirma: *“Mi árbol clasifica correctamente el 100 % de los datos de entrenamiento, por lo tanto, es un excelente modelo”*. Critique esta afirmación de manera rigurosa.
- d) Explique cómo la validación cruzada de k pliegues permite estimar el error de generalización y por qué resulta preferible a una única partición de retención (holdout) cuando se dispone de pocos datos.

Parte D. Clasificadores basados en reglas

Ejercicio 8. Derivación de reglas a partir de un árbol de decisión

Considere el árbol de decisión obtenido en el Ejercicio 2, inducido sobre el Conjunto de Datos 1.

- Derive el conjunto completo de reglas de clasificación, recorriendo cada camino desde la raíz hasta una hoja.
- Para cada regla, indique su cobertura —la cantidad de instancias del Conjunto de Datos 1 que satisface su antecedente— y su exactitud sobre dichas instancias.
- ¿El conjunto de reglas resultante es mutuamente excluyente y exhaustivo? Justifique su respuesta.
- Clasifique los siguientes solicitantes nuevos: **S1** (Ingreso = Medio, Historial = Malo, Deuda = Baja) y **S2** (Ingreso = Bajo, Historial = Bueno, Deuda = Alta).

Ejercicio 9. Conjunto ordenado de reglas frente a votación

Un sistema antifraude clasifica las transacciones como “Fraude” o “Legítima” mediante el siguiente conjunto de reglas:

R1: (Monto = Alto) Y (PaísDistinto = Si) -> Fraude
 R2: (HoraInusual = Si) -> Fraude
 R3: (Monto = Bajo) -> Legítima
 R4: (ClienteAntiguo = Si) -> Legítima
 Regla por defecto -> Legítima

Clasifique las tres transacciones de la Tabla 5 bajo dos esquemas: (i) un conjunto ordenado de reglas, es decir, una lista de decisión con prioridad $R1 > R2 > R3 > R4$; y (ii) una votación no ponderada de todas las reglas cuyo antecedente se satisface.

Tabla 5. Transacciones a clasificar en el Ejercicio 9.

Transacción	Monto	PaísDistinto	HoraInusual	ClienteAntiguo
T1	Alto	Sí	Sí	No
T2	Bajo	No	Sí	Sí
T3	Medio	No	No	No

- Indique la clase asignada a cada transacción en cada uno de los dos esquemas.
- Señale en qué transacciones difieren los resultados de ambos esquemas y explique la causa de la discrepancia.
- Discuta una ventaja y una desventaja de cada esquema de resolución de conflictos entre reglas.

Ejercicio 10. Generación directa de reglas: cobertura secuencial

El Conjunto de Datos 3 (Tabla 6) contiene 10 puntos en un espacio bidimensional, descritos por los atributos continuos x_1 y x_2 , y etiquetados con la clase “+” o “-”.

Tabla 6. Conjunto de Datos 3 — Puntos en el plano para el Ejercicio 10.

Punto	P1	P2	P3	P4	P5	P6	P7	P8	P9	P10
x_1	1	1	2	2	6	4	5	5	3	6
x_2	1	3	2	4	1	4	5	3	5	5
Clase	+	+	+	+	+	-	-	-	-	-

- Describa, con sus propias palabras, el algoritmo de cobertura secuencial para la generación directa de reglas.
- Aplique el algoritmo para construir un conjunto de reglas que cubra la clase “+”. Cada regla debe expresarse como una conjunción de condiciones sobre x_1 y x_2 y no debe cubrir ningún punto de la clase “-”.
- Indique cuántas reglas fueron necesarias y discuta qué consecuencias tendría permitir reglas con una cobertura muy baja.

Parte E. Preguntas teóricas de desarrollo

Responda de forma clara, precisa y fundamentada. Se valorará el uso correcto de la terminología técnica y la articulación de los conceptos.

1. Explique la diferencia entre aprendizaje supervisado y no supervisado, y ubique la tarea de clasificación dentro de esta taxonomía.
2. ¿Por qué el error de entrenamiento (error de resustitución) no constituye un estimador fiable del desempeño de un modelo sobre datos nuevos?
3. Compare el índice de Gini, la entropía y el error de clasificación como medidas de impureza. ¿Por qué la ganancia de información tiende a favorecer los atributos con muchos valores y de qué modo lo corrige la razón de ganancia?
4. Enuncie y justifique las principales ventajas y limitaciones de los árboles de decisión como clasificadores.
5. Explique el compromiso entre sesgo y varianza y relaciónelo con los fenómenos de subajuste y sobreajuste.
6. Compare los clasificadores basados en reglas con los árboles de decisión en términos de expresividad, interpretabilidad y facilidad de mantenimiento.
7. ¿En qué consiste el problema del desbalance de clases? ¿Por qué la exactitud resulta una métrica inadecuada en ese contexto y qué alternativas propondría?
8. Un clasificador basado en reglas y un árbol de decisión pueden representar el mismo conocimiento. Discuta en qué situaciones preferiría cada una de las dos representaciones.

Parte F. Práctica en R

Esta parte se resuelve en R. Se utilizará el conjunto de datos `PimaIndiansDiabetes` del paquete `mlbench` (768 observaciones; ocho atributos predictores numéricos y el atributo de clase diabetes, con valores pos y neg). El siguiente fragmento prepara el entorno de trabajo:

```
pkgs <- c("rpart","rpart.plot","caret","C50","mlbench")
install.packages(pkgs[!(pkgs %in% installed.packages()[,"Package"])]))
library(rpart); library(rpart.plot); library(caret)
library(C50); library(mlbench)
data(PimaIndiansDiabetes, package = "mlbench")
set.seed(2026)
```

Ejercicio 11. Árboles de decisión con rpart

- Cargue los datos y particiónelos en un 70 % de entrenamiento y un 30 % de prueba mediante `caret::createDataPartition`. Fije la semilla del generador de números aleatorios para garantizar la reproducibilidad.
- Induzca un árbol de decisión sobre el conjunto de entrenamiento con la función `rpart()` y visualícelo con `rpart.plot()`.
- Calcule el error de resustitución (sobre el conjunto de entrenamiento) y el error de generalización (sobre el conjunto de prueba) mediante `caret::confusionMatrix()`. Compare ambos valores y comente.
- Informe la exactitud, la sensibilidad, la especificidad y el estadístico Kappa obtenidos sobre el conjunto de prueba.

Ejercicio 12. Sobreajuste y poda en R

- Induzca un árbol «completo» fijando los hiperparámetros `rpart.control(minsplit = 2, cp = 0)` y compare su error de resustitución con su error de generalización. ¿Qué evidencia de sobreajuste observa?
- Utilice `caret::train()` con validación cruzada de 10 pliegues para seleccionar el valor óptimo del parámetro de complejidad `cp`.
- Genere la curva del error estimado por validación cruzada en función de `cp` e interprétela.
- Compare el desempeño del árbol completo, el árbol por defecto y el árbol podado sobre el conjunto de prueba. Extraiga una conclusión.

Ejercicio 13. Clasificador basado en reglas en R

- Induzca un clasificador basado en reglas con el algoritmo C5.0 (paquete `C50`), utilizando la opción `rules = TRUE`, sobre el mismo conjunto de entrenamiento del Ejercicio 11.
- Inspeccione el conjunto de reglas generado con `summary()` e interprete dos de las reglas obtenidas.
- Evalúe el clasificador de reglas sobre el conjunto de prueba y compare su desempeño con el del árbol de decisión del Ejercicio 11.

- d)** Discuta las diferencias de interpretabilidad entre el árbol de decisión y el conjunto de reglas. Como alternativa, puede emplearse el método "PART" mediante `caret::train()` con el paquete `RWeka`.

Referencias

- Hahsler, M. (2025). *An R companion for Introduction to Data Mining*. Recuperado de https://mhahsler.github.io/Introduction_to_Data_Mining_R_Examples/
- Hahsler, M. (2025). *Introduction to Data Mining — Lecture slides* [Material de cátedra]. Basado en Tan, Steinbach, Karpatne y Kumar. Licencia Creative Commons BY-SA 4.0.
- Tan, P.-N., Steinbach, M., Karpatne, A., & Kumar, V. (2019). *Introduction to data mining* (2.ª ed.). Pearson.
- Therneau, T., & Atkinson, B. (2025). *rpart: Recursive partitioning and regression trees* [Paquete de R].
- Kuhn, M. (2024). *caret: Classification and regression training* [Paquete de R].